Tabela Hash

Prof. Jefferson T. Oliva

Algoritmos e Estrutura de Dados I (AE22CP)
Engenharia de Computação
Departamento Acadêmico de Informática (Dainf)
Universidade Tecnológica Federal do Paraná (UTFPR)
Campus Pato Branco

DAINF
DEPARTAMENTO ACADÊMICO DE INFORMÁTICA
CÂMPUS PATO BRANCO

UTFPR
UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

Sumário

- Tabela *Hash*
- Funções *Hash*
- Implementações

Introdução

- Vários métodos de busca realizam comparação de chaves durante o processamento

- Caso os dados estejam ordenados, a busca pode ter um custo de:
  - $O(n)$: busca sequencial
  - $O(\log n)$: busca binária
  - $O(\log(\log n))$: busca por interpolação (se os dados estiverem uniformemente distribuídos)
  - $O(max(m, n/m))$: busca sequencial indexada
  - $O(max(\log m, \log(n/m)))$: busca binária indexada (busca sequencial indexada + busca binária)

Introdução

- É possível encontrar uma chave sem a necessidade de compará-la com outras ou com custo constante ($O(1)$)?

Introdução

- Sabe-se que em arranjos é possível acessar os dados de forma direta através de um índice, ou seja, com custo de $O(1)$

- No entanto, como não é possível saber em qual índice a chave se encontra, geralmente teríamos que fazer uma busca, cuja abordagem depende de vários fatores:
  - Tamanho do arranjo
  - Distribuição dos dados
  - Ordenação
  - Etc

Sumário

Tabela *Hash*

Tabela *Hash*

- As tabelas *hash* (tabelas de espalhamento, tabelas de dispersão) são uma solução para este problema

- Uma tabela *hash* associa chaves e valores:
  - Chave: uma parte da informação que compõe o item a ser inserido ou buscado

  - Valor: posição onde o item deve estar no vetor

Tabela *Hash*

- *Hashing*: processamento de chave, cujo resultado é uma posição no arranjo

- A tabela *hash* usa uma função ***h***, onde:
  - A entrada é uma chave

  - A saída é a posição (endereço) onde essa chave deve ser inserida

- Com essa função, os dados podem não ser inseridos de forma ordenada
  - Por isso, o processo de aplicação de *hashing* é conhecido "como espalhamento"

Tabela *Hash*

- Ideia da tabela *hash*: particionar um conjunto de elementos (possivelmente infinito) em um número finito de classes:
  - B classes (endereços), de 0 a $B - 1$
  - Essas classes são chamadas de **buckets**

Tabela *Hash*

- Conceitos relacionados:
  - A função h é chamada de função *hash*
  - $h(k)$ retorna o valor *hash* de k
  - k pertence ao *bucket* $h(k)$

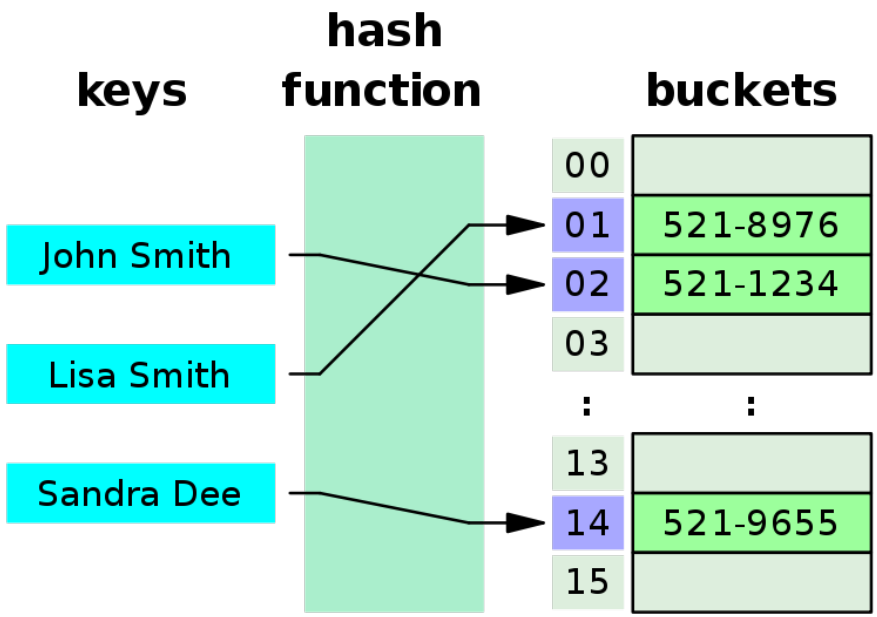

Fonte da figura:
`https://commons.wikimedia.org/w/index.php?curid=6471238`

Tabela *Hash*

- Colisão: ocorre quando a função *hash* produz o mesmo endereço para chaves diferentes

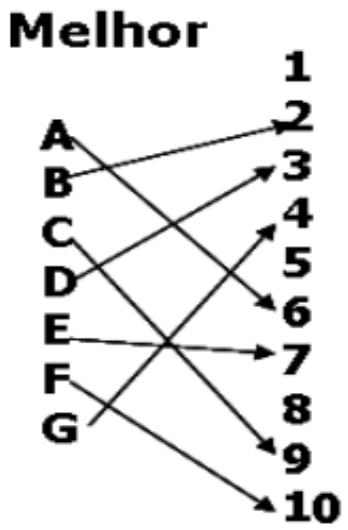

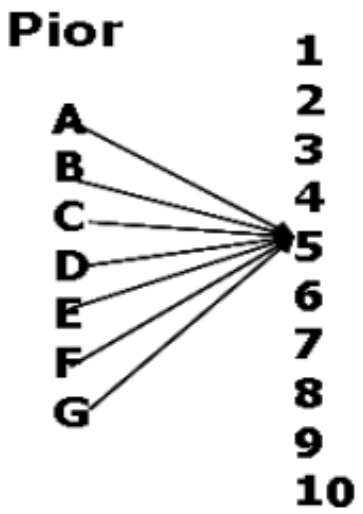

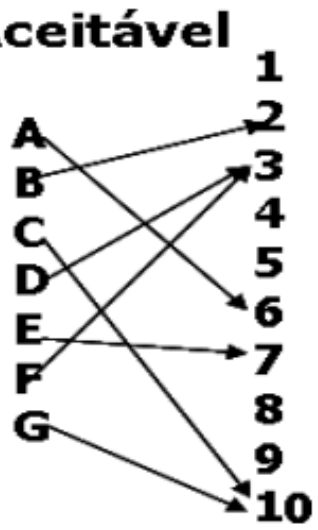

Tabela *Hash*

- Distribuição uniforme é muito difícil
- Existe chance de alguns endereços serem gerados mais de uma vez e de outros nunca serem gerados
- Segredos para um bom *hashing*:
  - Escolher uma boa função *hash* (em função dos dados)
    - Distribui uniformemente os dados, na medida do possível
    - Evita colisões
    - Fácil implementação
    - Rápida ao ser computada
  - Estabelecer uma boa estratégia para tratamento de colisões

Tabela *Hash*

- Exemplo de função *hash* simples e muito utilizada que produz bons resultados:
  - Para chaves inteiras, calcular o resto da divisão $k\%B$, sendo que o resto indica a posição de armazenamento
  - Para chaves do tipo *string*, tratar cada caractere como um valor inteiro (ASCII), somá-los e obter o resto da divisão por B
  - B deve ser primo, preferencialmente

Sumário

Funções *Hash*

Funções *Hash*

- A função *hashing* tem o objetivo de mapear o endereço (posição) de uma chave

- Existem diferentes possibilidades para implementar a função de *hashing*
  - Resto de Divisão
  - Multiplicação
  - Método da dobra

Funções *Hash*

- Resto de Divisão: a posição da chave na tabela é dada pelo resto da divisão entre a mesma pelo tamanho da tabela
  - Exemplo: Seja B um arranjo de 7 elementos e deseja-se a inserção das chaves 1, 5, 10, 20, 25, 24

Funções *Hash*

- Resto de Divisão: a posição da chave na tabela é dada pelo resto da divisão entre a mesma pelo tamanho da tabela
  - Exemplo: Seja B um arranjo de 7 elementos e deseja-se a inserção das chaves 1, 5, 10, 20, 25, 24

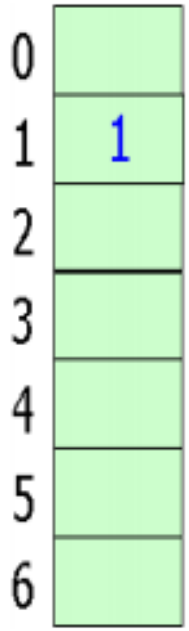

$1\%7 = 1$

Funções *Hash*

- Resto de Divisão: a posição da chave na tabela é dada pelo resto da divisão entre a mesma pelo tamanho da tabela
  - Exemplo: Seja B um arranjo de 7 elementos e deseja-se a inserção das chaves 1, 5, 10, 20, 25, 24

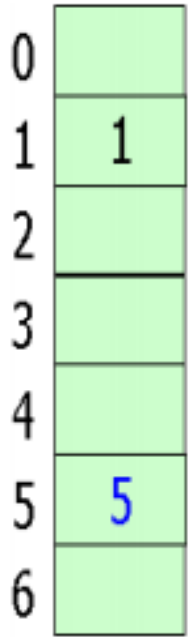

$5\%7 = 5$

Funções *Hash*

- Resto de Divisão: a posição da chave na tabela é dada pelo resto da divisão entre a mesma pelo tamanho da tabela
  - Exemplo: Seja B um arranjo de 7 elementos e deseja-se a inserção das chaves 1, 5, 10, 20, 25, 24

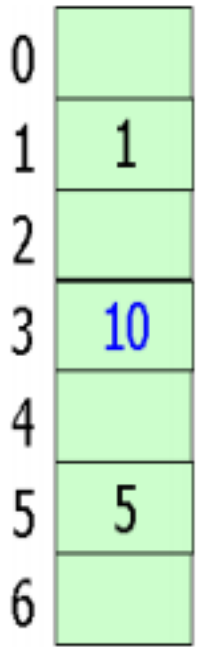

$10\%7 = 3$

Funções *Hash*

- Resto de Divisão: a posição da chave na tabela é dada pelo resto da divisão entre a mesma pelo tamanho da tabela
  - Exemplo: Seja B um arranjo de 7 elementos e deseja-se a inserção das chaves 1, 5, 10, 20, 25, 24

$20\%7 = 6$

Funções *Hash*

- Resto de Divisão: a posição da chave na tabela é dada pelo resto da divisão entre a mesma pelo tamanho da tabela
  - Exemplo: Seja B um arranjo de 7 elementos e deseja-se a inserção das chaves 1, 5, 10, 20, 25, 24

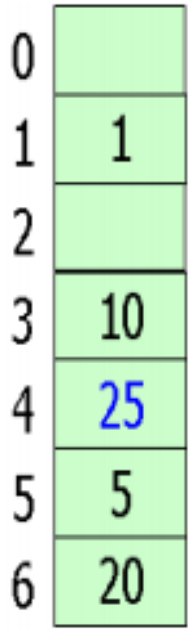

$25\%7 = 4$

Funções *Hash*

- Resto de Divisão: a posição da chave na tabela é dada pelo resto da divisão entre a mesma pelo tamanho da tabela
  - Exemplo: Seja B um arranjo de 7 elementos e deseja-se a inserção das chaves 1, 5, 10, 20, 25, 24

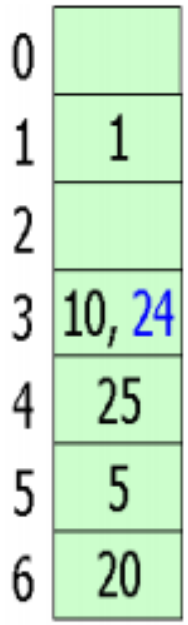

$24\%7 = 3$ (**Colisão**)

Funções *Hash*

- Multiplicação: a chave é multiplicada por uma constante $0 < c < 1$
  - Seleção da parte fracionária da multiplicação da chave pela constante
  - Multiplicar essa parte pelo tamanho da tabela
  - A parte inteira dessa última multiplicação é usada como posição

Funções *Hash*

- Multiplicação: a chave é multiplicada por uma constante $0 < c < 1$
  - Exemplo:
    - Tamanho da tabela $= 30$, $chave = 20$, $c = 0,26$
    - $chave * c = 5,2$
    - Parte fracionária $= 0,2$
    - Tamanho da tabela * parte fracionária $= 6,0$
    - Parte inteira $= 6$ (o item de chave 20 será guardado em na posição 6)

Funções *Hash*

- Método da dobra: a chave é interpretada como uma sequência de dígitos escrita em um papel
  - Enquanto a chave for maior que o tamanho da tabela, o papel vai sendo dobrado ao meio e os dígitos que se sobrepõe são somados sem levar em consideração o "vai um"

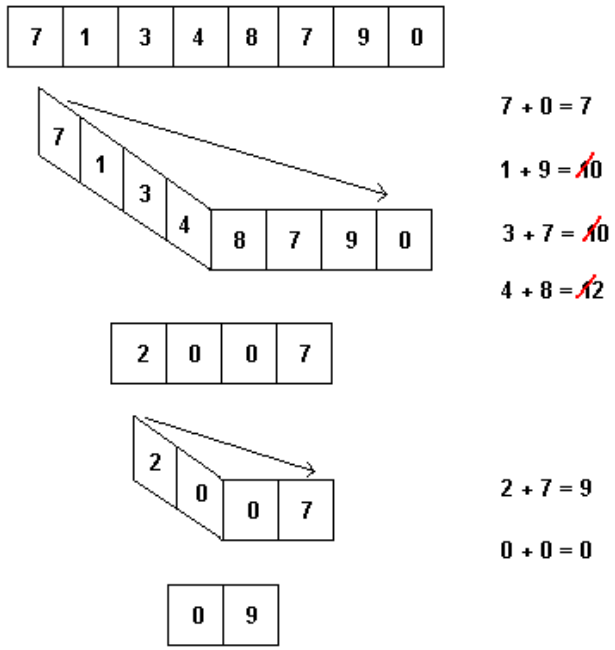

Funções *Hash*

- Colisões
  - Qualquer função *hashing* pode acarretar em colisões (chaves diferentes ocupam a mesma posição)

- Uma função *hashing* é perfeita quando chaves diferentes sempre são mapeadas para posições diferentes

- Uma função *hashing* é imperfeita quando podem acontecer colisões

Funções *Hash*

- *Hash* universal:
  - A função *hash* é escolhida aleatoriamente no início de cada execução, de forma que minimize/evite tendências das chaves
  - Por exemplo, $h(k) = (A * k + B)\%P$
    - P é um número primo maior do que a maior chave k
    - A é uma constante escolhida aleatoriamente de um conjunto de constantes $\{0, 1, 2, ..., P-1\}$ no início da execução
    - B é uma constante escolhida aleatoriamente de um conjunto de constantes $\{1, 2, ..., P-1\}$ no início da execução
  - Diz-se que h representa uma coleção de funções universais

Sumário

Implementação

Implementação

- Na implementação a ser realizada nessa aula não tratará colisões
- O código será aprimorada na próxima aula para o tratamento de colisões
- Estrutura de dados simples para tabela *hash*

```
typedef struct{
   int tamanho;
   int *buckets;
}HashTable;
```

Implementação

- TAD simples para a tabela *hash*:

```
HashTable* gerarHT(unsigned int tam);

int procurar_chave(unsigned int chave, HashTable*
t);

int inserir_chave(unsigned int chave, HashTable* t);

int remover_chave(unsigned int kchave, HashTable*
t);

void imprimir_tabela(HashTable* t);

int liberar_tabela(HashTable* t);
```

Implementação

- Código para arquivo .c

```
static int hash_code(int chave, int tam_tab){
   return chave % tam_tab;
}

HashTable* gerarHT(unsigned int tam){
   HashTable* t = malloc(sizeof(HashTable));
   int i;

   t->tamanho = tam;
   t->buckets = malloc(tam * sizeof(int));

   for (i = 0; i < tam; i++)
    t->buckets[i] = -1;

   return t;
}
```

Implementação

- Código para arquivo .c

```
int procurar_chave(unsigned int chave, HashTable* t){
   int hc;

   if (t != NULL){
    hc = hash_code(chave, t->tamanho);

    if (t->buckets[hc] == chave)
      return hc;
   }

   return -1;
}
```

Implementação

- Código para arquivo .c

```
int inserir_chave(unsigned int chave, HashTable* t){
   int hc;

   if (t != NULL){
    hc = hash_code(chave, t->tamanho);

    if (t->buckets[hc] < 0){
      t->buckets[hc] = chave;

      return 1;
    }

    printf("Houve colisao ao tentar inserir a chave %d!\n",
chave);
   }

   return 0;
}
```

Implementação

- Código para arquivo .c

```
int remover_chave(unsigned int chave, HashTable* t){
   int pos = procurar_chave(chave, t);

   if (pos >= 0){
    t->buckets[pos] = -1;

    return 1;
   }else
    return 0;
}

void imprimir_tabela(HashTable* t){
   int i;

   if (t != NULL)
    for (i = 0; i < t->tamanho; i++)
      if (t->buckets[i] > -1)
        printf("%d:  %d\n", i, t->buckets[i]);
}
```

Implementação

- Código para arquivo .c

```
int liberar_tabela(HashTable* t){
   int i;

   if (t != NULL){
    free(t->buckets);
    free(t);

    return 1;
   }else
    return 0;
}
```

Referências I


Cormen, T. H., Leiserson, C. E., Rivest, R. L., Stein, C.
Introduction to Algorithms.
Third edition, The MIT Press, 2009.


Oliva, J. T.
Tabela Hash. AE22CP – Algoritmos e Estrutura de Dados I.
Notas de Aula. Engenharia de Computação.
Dainf/UTFPR/Pato Branco, 2020.


Rosa, J. L. G.
Métodos de Busca. SCE-181 – Introdução à Ciência da Computação II.
Slides. Ciência de Computação. ICMC/USP, 2018.


Ziviani, N.
Projeto de Algoritmos - com implementações em Java e C++.
Thomson, 2007.